TALLER DE CLASIFICACIÓN CON ÁRBOLES DE DECISIÓN

Curso de Inteligencia Artificial | De las preguntas de un árbol a la evaluación de sus predicciones

Estudiante: Santiago Parra Acuña	**Fecha:** 29 de Octubre de 2026
Asignatura: Inteligencia Artificial	**Modalidad:** Individual (Taller Práctico)

---

1. Formulación del Problema (0,6 puntos)

a) Identificación de Componentes de Aprendizaje Supervisado:

• **Unidad de Observación:** Un diamante individual presentado para clasificación gemológica de corte.

• **Características (X):** Quilates (peso en quilates, x1), Profundidad (% de profundidad respecto al diámetro, x2).

• **Etiqueta (y):** Clase de corte del diamante (variable cualitativa binaria). Clases posibles: **A (Aceptable), E (Excelente)** (Clase positiva convención: **A (Aceptable)**).

• **Justificación:** Es aprendizaje supervisado porque cada observación del conjunto de entrenamiento cuenta con sus atributos predictores X y su respectiva etiqueta de verdad terreno (ground truth) y conocida previamente. Es de clasificación porque la variable dependiente y es cualitativa/categórica y discreta (A o E), a diferencia de un problema de regresión donde el objetivo es un valor numérico continuo.

b) Definición Estructural de Componentes del Árbol:

• **Raiz:** Nodo inicial (profundidad 0) que contiene el 100% de los datos de entrenamiento (12 diamantes). Allí se evalúa la primera pregunta divisoria óptima.

• **Nodo interno:** Nodo intermedio de decisión que evalúa una condición sobre un predictor (ej. Quilates <= 0.50) para particionar aún más un subconjunto impuro de diamantes.

• **Rama:** Enlace lógico y direccional que conecta un nodo con sus descendientes según el cumplimiento (x <= t) o incumplimiento (x > t) de la condición evaluada.

• **Hoja:** Nodo terminal que carece de hijos. Representa la decisión final del modelo y asigna una etiqueta de clase (A o E) por mayoría o por la regla de desempate establecida.

c) Fuga de Datos y Disponibilidad de Variables:

• **Campo 'Resultado final de la inspección':** El campo 'resultado final de la inspección' NO debe incluirse. Esto constituye fuga de datos (data leakage), dado que es una variable generada con posterioridad o simultáneamente al juicio de clasificación. En el momento de producción/inferencia, este campo no estará disponible de antemano. Incluirlo falsearía la capacidad predictiva del modelo en el mundo real.

• **Condición sobre el Precio:** Para poder incluir el 'precio', debe asegurarse estrictamente que sea una característica disponible ANTES de clasificar el corte (ej. costo de extracción o compra bruta previa), y que bajo ninguna circunstancia sea un precio de venta determinado a partir del corte ya asignado, pues de lo contrario crearía una fuga circular.

2. Selección de la Raíz con el Índice Gini (1,2 puntos)

a) Conteo de Clases e Impureza de la Raíz:
El conjunto cuenta con |S| = 12 muestras (6 clase A, 6 clase E). Las proporciones son p_A = 6/12 = 0.5000 y p_E = 6/12 = 0.5000. Impureza de la raíz: **G(S) = 1 - (0.5^2 + 0.5^2) = 1 - 0.5000 = 0.5000**.

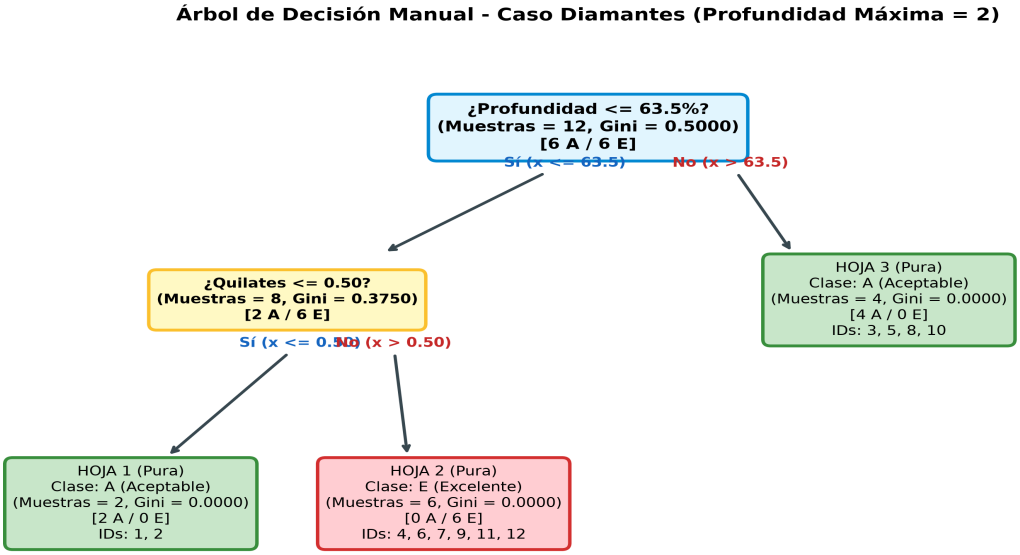
b) Tabla Comparativa de Preguntas Candidatas para la Raíz:

Pregunta	nL	A/E en SL	G(SL)	nR	A/E en SR	G(SR)	Gdiv	DeltaG
Quilates <= 0.75	5	4/1	0.3200	7	2/5	0.4082	0.3714	0.1286
Profundidad <= 63.5	8	2/6	0.3750	4	4/0	0.0000	0.2500	0.2500

c) Elección Justificada y Discusión Metodológica:
• **Elección de Raíz:** Se selecciona la pregunta **'Profundidad <= 63.5'** al generar la mayor reducción de impureza (**ΔG = 0.2500**) frente a 'Quilates <= 0.75' (ΔG = 0.1286). Además, produce una rama derecha completamente pura (G = 0.0000 con 4 diamantes Aceptables).
• **¿Por qué no promediar sin considerar tamaños?:** Un promedio simple asignaría igual peso a subconjuntos con muy pocas observaciones que a subconjuntos con la gran mayoría de datos. La probabilidad de que un elemento caiga en un nodo hijo depende de su tamaño relativo (|S_L| / |S|), por lo que la impureza esperada DEBE ponderarse.
• **No optimalidad global:** Comparar únicamente dos preguntas arbitrarias no demuestra optimalidad global porque existen otros posibles puntos medios entre los valores continuos de ambas variables que no fueron evaluados en esta comparación binaria.

3. Construcción e Interpretación del Árbol (1,0 punto)

a) Partición del Hijo Impuro (Rama Izquierda: Profundidad <= 63.5):
El nodo izquierdo S_L contiene 8 diamantes (IDs: 1, 2, 4, 6, 7, 9, 11, 12) con 2 A y 6 E (G = 0.3750).
Al ordenar los valores únicos de Quilates en S_L [0.3, 0.4, 0.6, 0.8, 0.9, 1.1, 1.3, 1.4], el punto medio entre 0.4 y 0.6 es **Quilates <= 0.50**. Esta división separa:
• S_LL (Quilates <= 0.50): IDs [1, 2] -> 2 A, 0 E. **G(S_LL) = 0.0000 (Puro)**.
• S_LR (Quilates > 0.50): IDs [4, 6, 7, 9, 11, 12] -> 0 A, 6 E. **G(S_LR) = 0.0000 (Puro)**.
Impureza ponderada resultante: G_div = (2/8)(0) + (6/8)(0) = 0.0000 -> **ΔG = 0.3750 (Ganancia Máxima)**.



c) Reglas Derivadas y Clasificación Trazable de Casos Nuevos (N1-N4):

• **Regla Hoja 1:** SI Profundidad <= 63.5 Y Quilates <= 0.50 ENTONCES Clase = A [Soporte: 2 A, 0 E]
• **Regla Hoja 2:** SI Profundidad <= 63.5 Y Quilates > 0.50 ENTONCES Clase = E [Soporte: 0 A, 6 E]
• **Regla Hoja 3:** SI Profundidad > 63.5 ENTONCES Clase = A [Soporte: 4 A, 0 E]

Caso	Quilates	Profundidad	Predicción	Recorrido / Traza
N1	0.45	62.0	**A**	Raíz -> Profundidad <= 63.5 (Rama Izq) -> Quilates <= 0.50 (Rama Izq) -> Hoja 1 [A]
N2	1.15	64.0	**A**	Raíz -> Profundidad > 63.5 (Rama Der) -> Hoja 3 [A]
N3	0.85	61.0	**E**	Raíz -> Profundidad <= 63.5 (Rama Izq) -> Quilates > 0.50 (Rama Der) -> Hoja 2 [E]
N4	0.55	63.5	**E**	Raíz -> Profundidad <= 63.5 (Rama Izq) -> Quilates > 0.50 (Rama Der) -> Hoja 2 [E]

• **¿Puede afirmarse acierto en N1-N4?:** No es posible afirmar con certeza matemática si el modelo acertó o falló en los casos N1 a N4, debido a que dichas observaciones son no etiquetadas (carecen de ground truth). En aprendizaje automático, el rendimiento solo puede contrastarse frente a datos con etiquetas reales de referencia.

• **Exactitud del 100% sobre 12 filas:** Una exactitud del 100% sobre las 12 filas de entrenamiento demuestra que el árbol tiene suficiente capacidad expresiva para separar perfectamente las clases del conjunto observado (ajuste perfecto de la muestra). Sin embargo, NO demuestra capacidad de generalización hacia nuevas observaciones del mundo real. De hecho, lograr 100% en una muestra tan pequeña (12 casos) conlleva un alto riesgo de sobreajuste (overfitting) o de memorización de peculiaridades muestrales no generalizables.

4. Evaluar las Predicciones en Clasificación Binaria (0,8 puntos)

a) Matriz de Confusión y Métricas de Rendimiento (Clase Positiva = A):
Conteo independiente (N=20): **VP = 6** (Real A, Pred A), **VN = 9** (Real E, Pred E), **FP = 3** (Real E, Pred A), **FN = 2** (Real A, Pred E).

Métrica	Fórmula y Sustitución	Resultado	Interpretación Técnica y de Negocio
Exactitud	Exactitud = (VP + VN) / N = (6 + 9) / 20 = 15 / 20	**0.7500** (75.00%)	El 75.00% de las predicciones globales emitidas por el modelo fueron acertadas (15 de 20 casos clasificados correctamente entre ambas clases).
Precision	Precision = VP / (VP + FP) = 6 / (6 + 3) = 6 / 9	**0.6667** (66.67%)	De todos los diamantes que el clasificador etiquetó como Aceptable (clase positiva A), únicamente el 66.67% (6 de 9) eran verdaderamente Aceptables; el 33.33% restante eran falsas alarmas.
Recall	Recall = VP / (VP + FN) = 6 / (6 + 2) = 6 / 8	**0.7500** (75.00%)	De la totalidad de diamantes verdaderamente Aceptables (8 casos reales en el conjunto), el modelo fue capaz de detectar y recuperar exitosamente el 75.00% (6 casos).
F1	F1 = 2*VP / (2*VP + FP + FN) = (2 * 6) / (2*6 + 3 + 2) = 12 / 17	**0.7059** (70.59%)	La media armónica entre precisión y exhaustividad para la clase A es 0.7059 (70.59%), mostrando un balance equilibrado pero penalizado por las 3 falsas alarmas y 2 omisiones.

b) Análisis Asimétrico de Costos de Error:

• **Excelente clasificado como Aceptable (FP respecto a A):** Escenario de Comercialización Mayorista / Venta de Inventario: Si la empresa comercializa las gemas con base en esta clasificación automática, vender un lote de diamantes Excelentes al precio depreciado de diamantes Aceptables causará una severa pérdida financiera directa (lucro cesante inmediato por vender un activo premium a precio de descuento).

• **Aceptable clasificado como Excelente (FN respecto a A):** Escenario de Laboratorio Certificador de Lujo / Joyería de Alta Gama: Si un laboratorio de prestigio expide certificados de autenticidad y califica un diamante defectuoso como 'Excelente', el comprador final o un perito auditor externo detectará el engaño. Las consecuencias serán demandas por publicidad engañosa, demandas comerciales, revocación de licencias y pérdida total de reputación institucional.

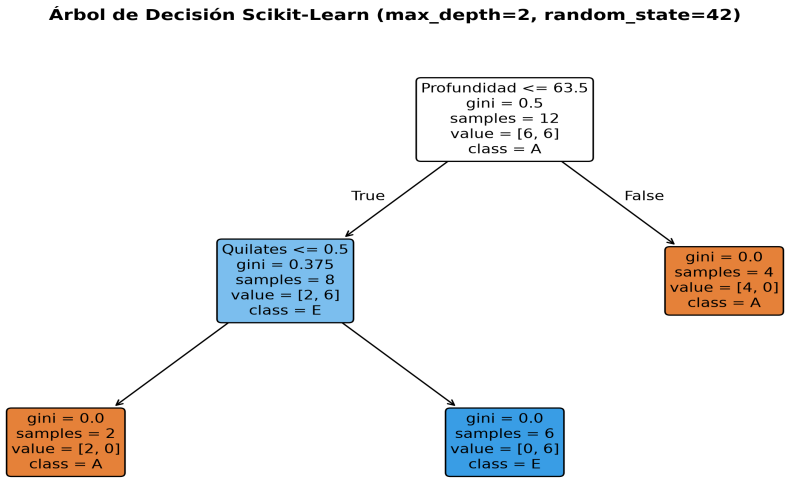
c) Conjunto Desbalanceado (95 A y 5 E) con Predictor Mayoritario:

• **Exactitud Global:** Exactitud = 95 / 100 = 0.9500 (**95.00%**).
• **Recall de la clase E:** Recall(E) = VP_E / (VP_E + FN_E) = 0 / 5 = 0.0000 (**0.00%**).
• **Conclusión:** Este resultado ilustra la 'paradoja de la exactitud' en conjuntos desbalanceados. Una exactitud del 95% aparenta un rendimiento excelente a nivel superficial, pero oculta que el modelo es 100% inútil para la clase minoritaria E (que con frecuencia es la clase de mayor interés o criticidad). Por esta razón es imprescindible evaluar métricas desagregadas por clase (Recall, Precisión, F1 por clase) o métricas macro-ponderadas (como Macro F1), las cuales revelan inmediatamente el colapso del clasificador.

5. Implementación y Generalización en Python (1,4 puntos)

Parte A: Verificación en Python del Caso Sintético Diamantes (0,3 puntos)

Se entrenó un DecisionTreeClassifier(criterion='gini', max_depth=2, random_state=42) sobre las 12 observaciones. El árbol resultante coincide exactamente con la solución manual: raíz en **Profundidad <= 63.50**, nodo hijo izquierdo en **Quilates <= 0.50**, y hojas puras en profundidad 1 y 2. Las predicciones para N1 a N4 coinciden en un 100% con el árbol manual (N1: A, N2: A, N3: E, N4: E).



Parte B: Experimento de Generalización con Conjunto Iris (1,1 puntos)

• **Particiones Estratificadas (60%/20%/20%):** La estratificación garantiza que cada partición (Train: 90 flores, Val: 30 flores, Test: 30 flores) mantenga con exactitud la proporción original de las clases (33.3% por cada especie, es decir, exactamente 30-30-30 en Train, 10-10-10 en Val y 10-10-10 en Test). Sin estratificación, particiones aleatorias en muestras reducidas pueden subrepresentar o sesgar la distribución de alguna de las especies.

• **Semilla Fija (random_state=42):** El uso de una semilla fija (random_state=42) es un principio fundamental de la reproducibilidad científica. Permite que cualquier investigador o evaluador replique con exactitud matemática las particiones y resultados obtenidos, garantizando la trazabilidad experimental y evitando sesgos por re-muestreo favorable.

Tabla Comparativa de Candidatos (Entrenamiento vs Validación):

Candidato	Train Acc	Val Acc	Val F1 Macro	Prof. Efectiva	Num Hojas
max_depth=1	0.6667	0.6667	**0.5556**	1	2
max_depth=3	0.9889	0.9000	**0.8997**	3	4
max_depth=None	1.0000	0.9333	**0.9333**	4	5

• **Selección del Modelo:** El modelo seleccionado es 'max_depth=None'. Alcanzó el mayor desempeño en validación con un F1 Macro de 0.9333 y una exactitud de validación de 0.9333. Superó a max_depth=1 (que incurre en subajuste severo al no poder separar 3 clases con solo 1 división) y a max_depth=3 en capacidad discriminativa.

• **Sobreajuste y Subajuste:** Para max_depth=None, la exactitud en entrenamiento es perfecta (100.0%, 90/90 flores), mientras que en validación obtiene 93.33% (28/30 flores). La brecha de 6.67% entre entrenamiento y validación es una señal clásica de ligera memorización o sobreajuste incipiente en las hojas más profundas (profundidad efectiva = 4, 5 hojas). Por otro lado, max_depth=1 exhibe subajuste (underfitting) claro (66.67% en train y val), incapaz de modelar la complejidad del problema.

Evaluación Final en Conjunto de Prueba y Comparación con Referencia:

Modelo	Rol Metodológico	Exactitud Prueba	F1 Macro Prueba
Árbol Seleccionado (max_depth=None)	Modelo Ganador del Proceso de Selección	**0.9333**	**0.9333**
DummyClassifier (most_frequent)	Línea Base Ingenua (Referencia)	**0.3333**	**0.1667**

Explicación de Caminos en el Árbol Seleccionado:

• **Camino 1: Identificación Directa de Iris-setosa (Hoja de Profundidad 1):** Raíz -> ¿petal length (cm) <= 2.45? -> SÍ (Rama Izquierda) -> Hoja Terminal [Clase: Setosa]
Interpretación: Este camino demuestra la perfecta separabilidad morfológica lineal de la especie Iris-setosa respecto a las demás especies. Una flor cuyo pétalo mide menos de 2.45 cm de longitud es, de forma determinista, una Setosa, no requiriendo evaluar ninguna otra dimensión.

• **Camino 2: Discriminación de Iris-virginica por Pétalo Robusto (Hoja de Profundidad 2):** Raíz -> ¿petal length (cm) > 2.45? -> NO (Rama Derecha) -> ¿petal width (cm) > 1.65? -> NO (Rama Derecha) -> Hoja Terminal [Clase: Virginica]
Interpretación: Cuando el pétalo es largo (> 2.45 cm), el árbol examina el grosor del pétalo (petal width). Si el ancho supera los 1.65 cm, el espécimen posee los pétalos gruesos característicos de Iris-virginica. Este camino aísla eficientemente a la inmensa mayoría de flores Virginica en tan solo 2 niveles de decisión.

• **Alcances y Limitaciones (Tamaño de Muestra N=30):** El conjunto de prueba consta de únicamente 30 observaciones (10 por clase). En un conjunto tan pequeño, cada flor individual mal clasificada representa una variación de 3.33% en la exactitud global y 10.0% en el recall de esa clase específica. Por ende, los intervalos de confianza estadística son amplios y no debe asumirse que el 93.33% sea exacto ante perturbaciones mayores de muestreo o datos recolectados en diferentes estaciones o regiones geográficas.

• **Regla Metodológica:** Es un principio inquebrantable de la ciencia de datos no modificar la selección de hiperparámetros ni reentrenar el modelo tras observar el rendimiento en el conjunto de prueba. Hacerlo contaminaría la evaluación final y anularía la condición de conjunto independiente no sesgado (leakage).

6. Preguntas para Socializar y Conclusiones Generales

¿Por qué una hoja pura no garantiza aciertos futuros?

Una hoja pura indica únicamente que el modelo separó a la perfección los datos históricos de entrenamiento en esa región. No garantiza aciertos en producción porque datos no vistos pueden presentar solapamiento estocástico de clases, variabilidad o ruido. Si una hoja pura se forma con pocas muestras (ej. 1 o 2 observaciones), suele responder a memorización de ruido (sobreajuste).

¿Qué cambia al limitar la profundidad?

Limitar la profundidad (poda previa o pre-pruning) restringe la complejidad y capacidad de memorización del árbol, introduciendo un sesgo controlado que reduce significativamente la varianza. Conduce a árboles más parsimoniosos, explicables y robustos ante datos futuros. Sin embargo, si se limita en exceso (ej. max_depth=1), puede caer en subajuste al no capturar interacciones no lineales.

¿Por qué F1 macro resulta útil al comparar las tres especies?

F1 macro calcula la media aritmética simple de los F1 scores de cada clase, ponderando por igual a cada especie botánica sin importar el volumen de muestras. En escenarios con ligero o severo desbalance, evita que una clase mayoritaria oculte un pésimo desempeño en clases minoritarias.

¿Qué información adicional necesitaría para usar el modelo fuera del taller?

Para un despliegue operativo en el mundo real se requiere: 1) Matriz de costos/beneficios económicos del negocio. 2) Protocolos de monitoreo de deriva de datos y conceptos (Data Drift y Concept Drift). 3) Atributos complementarios de estándar industrial (ej. en diamantes: proporciones de tabla, color, claridad y simetría; en botánica: condiciones de suelo y clima). 4) Calibración de probabilidades para emitir niveles de confianza y abstención ante incertidumbre.

Figura A: Árbol de Decisión Seleccionado para Iris (max_depth=None, Efectiva=4)

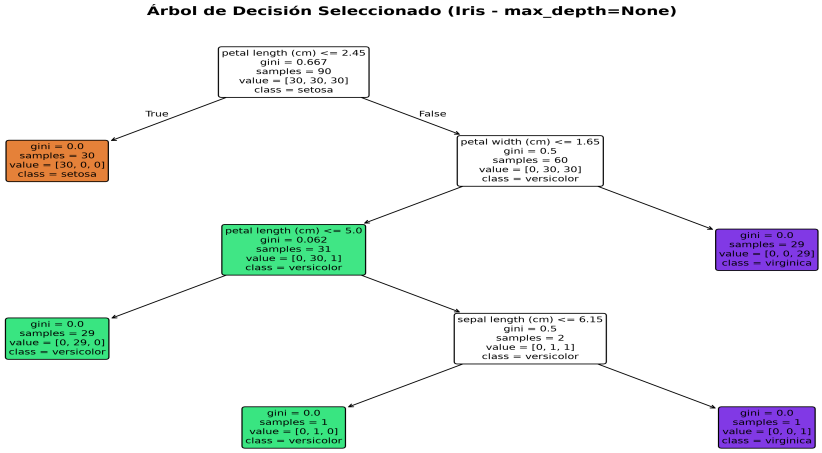


Figura B: Matriz de Confusión en Conjunto de Prueba (Test Set, N=30)

